

Guía de estudio — Auditoría del modelado

Proyecto Integrador G8 · preparación de defensa (9-jun-2026)

Frente de modelado (Sara) — revisión Yeison + Claude Code

Estado: modelado, datos, tablero e informe CERRADOS

Contents

TL;DR — estado actual (todo cerrado)	2
Parte 0 — El mapa mental: qué corre dónde y por qué	2
Parte 1 — Dónde se cruzan los dos modelos (el insight central)	3
Parte 2 — Modelo de propensión (dudas, una por una)	3
2.1 El “Caveat Abierto (Riesgo Técnico)”	3
2.2 Por qué estos baselines y modelos (no otros)	3
2.3 Feature importance: built-in vs permutación	4
2.4 Qué aporta “GBM (LightGBM) + Optuna”	4
2.5 Cómo interpretar la evaluación en test	4
2.6 El umbral operativo: implicación de negocio	5
2.7 ¿Genera valor o “modelamos por modelar”?	5
Parte 3 — Qué hace 03_drift_split_diagnostico	5
Parte 4 — Clustering (dudas, una por una)	6
4.1 ¿“Cruzar con la conversión” = comparar o cruzar con el modelo?	6
4.2 ¿Solo para el A/B? No	6
4.3 El gráfico de §6 (visitante × propensión)	6
4.4 Las visualizaciones de §7: cuáles sirven	6
4.5 Los 5 segmentos (tabla de defensa)	7
Parte 5 — 06_scoring_mlflow_databricks (de “no corría” a CERRADO)	7
5.1 Qué hace	7
5.2 El patrón correcto (Serverless)	8
5.3 El bug que cazamos (y por qué importa)	8
5.4 Estado: CERRADO	8

Síntesis — estado y qué falta	8
Apéndice — matices verificados para el Q&A (no tropezar)	9
Apéndice — frases-ancla del profe (para soltar en la defensa)	9

Cómo leer esto. Es la auditoría completa del frente de modelado, organizada en 6 bloques (Parte 0 a Parte 5) + síntesis. Cada parte responde “qué se hace, por qué, cómo se defiende”. Las cifras están **verificadas contra el repo final**. Los matices marcados (**ojo defensa**) son trampas a evitar al hablar.

TL;DR — estado actual (todo cerrado)

- **Propensión y clustering:** cerrados y verificados. Modelo final **LightGBM+Optuna** calibrado.
- **Contrato 2 (scoring):** materializado y **correcto** en Delta (19.71 M filas; avg prob 0.060 ≈ tasa base).
- **Informe + tablero:** consolidados; main conciliado y pusheado.
- **Lo único vivo:** la PPT y el ensayo de defensa.

Parte 0 — El mapa mental: qué corre dónde y por qué

Hay **cinco notebooks** repartidos en dos mundos:

Notebook	Dónde	Motor	Qué hace
01_extraccion_gold_a_parquet	Databricks	Spark	Vuelca la Gold Delta a un parquet (gold_snapshot)
02_modelado_propension	Local	pandas/sklearn	Entrena y evalúa la propensión
03_drift_split_diagnostico	Databricks	Spark	Diagnóstico de deriva para justificar el split
04_clustering	Local	pandas/sklearn	Clustering de visitantes
06_scoring_mlflow_datacontract	Databricks	pandas+Spark	Scoring batch + MLflow + Contrato 2

La estrategia es “entrena local, sirve en la nube”: Databricks materializa la Gold (~4.7 GB) como parquet, ese parquet se baja al repo local, el **modelado de exploración (02, 04) corre local** en pandas/sklearn (Optuna, calibración, permutación — el ecosistema que enseña el curso), y lo **distribuido/producción vuelve a Databricks** (drift sobre 109 M eventos crudos en 03, y scoring + MLflow + Contrato 2 en 06).

No es “prototipo local y reimplemento todo en Spark”. Es **división por naturaleza de la tarea**: Spark donde el dato es grande o es streaming; pandas/sklearn donde el cómputo es modelado tabular sobre la sesión agregada (~23 M filas que caben en memoria, y donde SparkML es más pobre que sklearn).

Respuesta defendible ante el profe de Grandes Datos (pregunta fija del jurado): *“Usamos Spark donde el volumen lo justifica —ingesta streaming de 109 M eventos, Medallion en Delta, diagnóstico de deriva, materialización del scoring*

a Delta— y bajamos a pandas/sklearn para el modelado tabular porque la unidad de análisis es la sesión agregada (~23 M filas, ~4.7 GB), que cabe en memoria y donde el ecosistema de ML es superior. Distribuir un sklearn de 23 M filas no aportaba nada y perdía herramientas del estándar.” Esto convierte “¿por qué no todo en Spark?” en una **decisión por tamaño + patrón**, no por defecto.

Parte 1 — Dónde se cruzan los dos modelos (el insight central)

El cruce clasificador × clustering ocurre en **tres niveles**:

1. **Cruce conceptual (en 04 §6)**: se calcula la **tasa de conversión real por cluster** y se grafica contra el valor. Identifica **C3 «electrónica gama media»** como el segmento objetivo: 29.3 % del tráfico, conversión 8.4 % (la mayor), pero 91.6 % no compra → bolsa recuperable. Responde *qué tipo de visitante concentra la oportunidad*.
2. **Cruce individual (en 06, el Contrato 2)**: aquí se unen de verdad. El clustering dice *en qué segmento* está la sesión; el modelo de propensión dice *con qué probabilidad* compra esa sesión. **El segmento dice dónde enfocar; el modelo dice a quién exactamente**. Dentro de C3 hay sesiones con 5 % y con 40 % de probabilidad.
3. **Cruce operativo**: el Contrato 2 (user_session, prob_calibrada, segmento) alimenta el targeting del A/B (Yeison) y la matriz de oportunidad del tablero (Kelly).

Estado: el cruce individual ya está MATERIALIZADO (antes solo narrado). El Contrato 2 corrió correcto en Databricks (19.71 M filas, avg prob 0.060).

¿El clustering usa la propensión predicha como feature? NO — y es correcto. Meter la propensión predicha sería circular (agruparías por la salida de otro modelo) y contaminaría la interpretación de “tipos de visitante”. El clustering describe *quién es* el visitante por su conducta; la propensión es una capa separada que se cruza después, **por sesión, en el Contrato 2** (no anidada).

Parte 2 — Modelo de propensión (dudas, una por una)

2.1 El “Caveat Abierto (Riesgo Técnico)”

Es la honestidad intelectual frente a la **anomalía de noviembre**: en 14–17 nov hay un pico de cart con purchase deprimido. Dos explicaciones posibles: (a) comportamiento real cerca de Black Friday, o (b) artefacto del pipeline de medición. **No hay que resolver cuál es** para que el modelo sea válido, porque se **cuarentenó la ventana 14–17** (fuera de train y test). Es un **riesgo declarado y acotado**, no un bug. Para la defensa es bueno tenerlo escrito: viste la anomalía, la aislaste, y eres transparente sobre lo no confirmable con datos observacionales.

2.2 Por qué estos baselines y modelos (no otros)

La secuencia **Dummy → Logística → familias de árboles (RF/XGB/LGBM) → LightGBM+Optuna** existe por el estándar del profe:

- **Dummy** (“nadie compra”): expone la **trampa del accuracy** — 94.4 % accuracy y **PR-AUC 0.056** detectando cero compras. Fija el piso: superar 0.056 de PR-AUC, no 0.94 de accuracy.

- **Logística:** baseline probabilístico, lineal, interpretable (PR-AUC 0.097, $\sim 1.7\times$ el azar). Responde *cuánta señal captura un modelo lineal simple*; si un GBM costoso no le ganara claro, no estaría justificada su complejidad.
- **Por qué árboles/ensembles:** el problema es **tabular**, con **interacciones no lineales** (precio $\times$ categoría $\times$ ritmo), **escalas mixtas** (árboles invariantes a escala), **desbalance fuerte** (manejable con `scale_pos_weight`) e **importancia interpretable** (exigida por la rúbrica). Los GBM son el estado del arte en tabular.
- **Por qué estas tres familias:** cubren las tres estrategias de ensemble del curso — **RF = bagging**, **XGBoost = boosting** (referencia madura), **LightGBM = boosting histograma/leaf-wise**. El curso pide probar ≥ 2 familias bajo **misma CV, métrica y muestra** (comparación justa).
- **Por qué no CatBoost (ojo defensa):** ya no hay categóricas crudas de alta cardinalidad (se codificaron a numéricas). Mencionarlo como “considerado y descartado por ausencia de categóricas crudas” suma.
- **Por qué LightGBM (matiz fino):** las tres familias quedan **empatadas dentro del ruido** (XGB 0.1185 vs LGBM 0.1184, diferencia $<$ variabilidad entre folds). Se elige LightGBM por **menor brecha de overfitting (0.018 vs 0.027)** $\rightarrow$ generaliza mejor, **no** porque tenga mejor score. Cierre: “*lo que mueve la aguja es el tuning, no la familia.*”

2.3 Feature importance: built-in vs permutación

Los árboles dan importancia intrínseca, pero el notebook usa **ambas** y la lectura válida es la **permutación**:

- **Built-in split** (nº de cortes): sesga hacia features de **alta cardinalidad**.
- **Built-in gain** (reducción de impureza): más fiable, pero medida interna sobre el train.
- **Permutación:** baraja una feature en datos **no vistos** (test) y mide cuánto **cae el PR-AUC** $\rightarrow$ mide importancia respecto a la métrica que importa, agnóstica al modelo.

El caso estrella `electronics_view_share`: split 0.042 (casi al fondo) vs permutación **0.203 (#2)**. Es de **baja cardinalidad** (valores 0/0.5/1): se usa en pocos cortes pero cada uno es muy informativo. “*Si nos quedamos con el split count, habríamos descartado erróneamente la feature de electrónica.*”

Qué dicen (negocio): las top por permutación son `max_price_viewed`, `electronics_view_share`, `avg_price_viewed` $\rightarrow$ **lo que predice la compra es cuán caro/electrónico es lo que miras, no cuánto navegas**. Triangula con EDA y clustering: tres análisis independientes, un mismo insight. **SHAP** solo como capa extra (cero menciones en el curso); la permutación es la base.

2.4 Qué aporta “GBM (LightGBM) + Optuna”

Convierte “un LightGBM razonable” en “el LightGBM **justificado**”. Optuna hace **HPO como diseño experimental** (TPE bayesiano) sobre 9 hiperparámetros; la **función objetivo** devuelve la media de PR-AUC en **StratifiedKFold 5-fold**; 20 trials. El tuning sube de 0.118 (sin tunear) a **CV 0.1235**.

R4 — variabilidad entre folds (verificado): el modelo elegido da **PR-AUC 0.1235 $\pm$ 0.0014** (5 folds, rango 0.122–0.126). La baja varianza confirma que **no es un máximo aislado** sino un resultado estable — exactamente lo que pide el profe (“*menor variabilidad puede ser mejor evidencia que un máximo aislado*”).

2.5 Cómo interpretar la evaluación en test

Subconjunto	PR-AUC	Brier	tasa
Test completo	0.1172	0.0515	0.0560
Test sin Black Friday	0.1115	0.0496	0.0536

Subconjunto	PR-AUC	Brier	tasa
Test solo BF (29–30)	0.1287	0.0559	0.0613

Lectura por capas:

1. **PR-AUC 0.1172 vs base 0.056** → **~2.1× el azar**. Nunca lo compares con 1.0; compáralo con la tasa base y los baselines. En evento raro (~5.6 %), el doble de la base es sólido.
2. **Test (0.1172) ≈ CV (0.1235)** → **no hay fuga ni sobreajuste**. Es el chequeo más importante: el desempeño fuera-de-tiempo casi iguala la validación interna.
3. **Con/sin Black Friday**: el **0.1115 ex-BF** es el número “**régimen normal honesto**” (úsalo de titular); el global 0.1172 incluye el empujón de BF. Reportar ambos es maduro.
4. **Brier 0.0515 (calibración)**: mide si las probabilidades son honestas (si dice 0.30, ~30 % compran). Bajo el baseline de la tasa base → calibración decente. Cumple *discriminar ≠ calibrar*.

(Ojo defensa) Dos tasas base: la **5.6 %** es la prevalencia del **test** (nov 24–30) — de ahí el Dummy 0.056 y el lift. La **0.0597** es la base limpia **global**. Usa 5.6 % para el lift, 0.0597 para describir los datos; no las mezcles.

2.6 El umbral operativo: implicación de negocio

El modelo entrega una probabilidad; el **umbral la vuelve decisión**. No es 0.5 (eso sería un error bajo desbalance). El **F1-óptimo es 0.092**:

Marca el **15 % de las sesiones**; dentro de ese 15 %, **precisión 12.1 %** (vs 5.6 % general) → **lift ~2.2×**; captura el **32 % de compradores** (recall) con solo el 15 % del tráfico.

La tabla de alternativas es la herramienta de decisión: **intervención barata** (banner/email) → umbral bajo ~0.09–0.10 (más alcance); **intervención cara** (cupón/agente) → umbral alto ≥0.20 (a 0.20 precisión ~30 %, a 0.30 ~50 %, pero marca <1 %). Conecta con el A/B (a quién se le muestra el incentivo dentro de C3/C4) y con la matriz deslizable del tablero. Frase: “*el modelo estima; el umbral decide*.”

(Ojo defensa) el umbral se calculó sobre el test → estrictamente roza “*si el test fija el threshold, deja de ser test*”. Defensa: es una **palanca de negocio** ajustable en producción, no un hiperparámetro del modelo, y se reporta como tal.

2.7 ¿Genera valor o “modelamos por modelar”?

Genera valor real: (1) un **ranking accionable** (el 15 % con 2.2× propensión → concentra el presupuesto); (2) el **diagnóstico del porqué** (precio + electrónica mandan); (3) el **insumo del experimento** (a quién targetear en el A/B). *La predicción es el instrumento; la decisión es el producto*.

Parte 3 — Qué hace 03_drift_split_diagnostico

Es un **notebook de evidencia, no de modelado** (no entrena nada). Corre en **Databricks/Spark** porque mira los crudos (109 M eventos). Su trabajo: **justificar empíricamente** las decisiones de partición que 02 da por hechas. Mide deriva por tres vías:

1. **Drift de etiqueta (conversión por sesión):** ~6.8 % (oct) → ~5.0 % (inicio nov) → ~6.1 % (fin nov). Drift moderado del *target*, no catastrófico. La vista diaria **expone el desplome corrupto** 15–17 nov.
2. **Drift de feature (PSI del precio):** umbrales 0.10/0.25; todos ≈ **0** (máx 0.0058) → el precio **no deriva**.
3. **Composición (event_type / categoría):** confirma el cart anómalo de noviembre.

Hallazgo clave: *el drift está en el comportamiento del target (conversión), no en la escala de las features (PSI≈0)*. Eso justifica **incluir noviembre en el train** (para calibrar la tasa al régimen de evaluación) y que **no haga falta reescalar**. Sustenta la **Opción C** (train oct+nov≤23 / test 24–30, *out-of-time*) y la cuarentena. La cuarentena ya quedó alineada a **14–17** en el markdown.

Parte 4 — Clustering (dudas, una por una)

4.1 ¿“Cruzar con la conversión” = comparar o cruzar con el modelo?

Hoy en 04 §6 es lo primero: la **tasa de conversión real por cluster** (no la predicción). El notebook la llama “propensión del segmento” pero es un promedio grueso. El cruce con el **modelo** (la predicción individual) ocurre **por sesión, en el Contrato 2 (06)** — y ya está materializado.

- **Features del clustering (12):** comportamiento de sesión (vistas, productos, marcas, categorías, duración, precios, electronics_share, revisit, ritmo). Escaladas con StandardScaler. **PCA solo para visualizar** (2 comp.), no como entrada de KMeans.
- **¿Usa la propensión predicha? NO** (correcto, evita circularidad).

4.2 ¿Solo para el A/B? No

Tres usos: (1) **definir el segmento objetivo del A/B** (C3, principal); (2) **insight para directivos** (§10 arquetipos: ~54 % de compradores es electrónica, élite premium 14 %, 5 % “investigador”); (3) **alimentar el tablero** + calidad de datos (C2 / DBSCAN detectan sesiones rotas).

4.3 El gráfico de §6 (visitante × propensión)

Scatter de **5 burbujas** (una por cluster): **X = conversión real**, **Y = “valor” proxy** (electronics_view_share × avg_price_viewed, **no monto real**), **tamaño = % de tráfico**. **C3 domina las dos dimensiones** (mayor conversión + alto valor) con volumen accionable. **Sirve para PPT/tablero** (legible), pero **siempre aclara que el eje Y es un proxy compuesto, no dólares**. Quita C2 (anómalo) del gráfico de presentación.

4.4 Las visualizaciones de §7: cuáles sirven

Gráfico	¿Limpio?	¿Dónde?
§6 burbujas (conversión × valor)	Sí, muy legible	PPT y tablero (el mejor para negocio)
§7.2 ejes de negocio (electronics × precio)	Aceptable, con bandas verticales	PPT/tablero con la advertencia de las bandas

Gráfico	¿Limpio?	¿Dónde?
§7.1 scatter PCA (57 % var)	Ruidoso/solapado, ejes abstractos	Solo backup técnico
§8 DBSCAN (KMeans vs DBSCAN)	Técnico	Solo si preguntan por validación

La verdad a defender: k=5 tiene **silhouette 0.30** (de las más bajas; k=2 daría 0.52 pero solo separa “electrónica sí/no”, demasiado grueso). Se eligió k=5 **por accionabilidad** (5 grupos nombrables con acción distinta), no por la métrica. Los clusters **se rozan** porque la estructura es un **gradiente, no islas** (lo confirma DBSCAN: 1 masa + 3.7 % ruido). Frase-ancla: *“el mejor k no es el que maximiza una métrica, es el que sostiene una partición defendible.”*

Cómo comunicarlo bien: no muestres el scatter PCA como “mira qué bien separan” (se ve solapado). **Lleva al frente la tabla de perfilado** (tamaño/conversión/precio/electrónica por cluster) y un **gráfico de barras de conversión por cluster** — mucho más convincente. Usa el de burbujas (§6) como cierre.

(Ojo defensa) dos correcciones de exactitud: - El cluster con **duración anómala ~15 días es C2** (sesiones rotas), **no C3**. C3 (target) tiene duración normal. - La numeración C0–C4 depende de la semilla → **nombra por perfil**, no por índice. El 06 reprodujo las proporciones del 04 (49.8/29.5/13.6/7.0/0.05 %), lo que es **evidencia de estabilidad**.

4.5 Los 5 segmentos (tabla de defensa)

Segmento	%	Conv.	Perfil
C3 Electrónica gama media	29.3 %	8.4 %	~99 % electrónica, ~\$257, decide rápido. OBJETIVO A/B
C4 Electrónica premium	13.8 %	5.8 %	Ticket ~\$1,024, mayor valor
C0 General bajo valor	49.8 %	4.9 %	No electrónica, ~\$154, mucho volumen
C1 Explorador que no cierra	7.0 %	3.2 %	Navega mucho (18.5 vistas), compra poco
C2 Anómalo	0.04 %	—	106 sesiones rotas (~14.6 días); calidad de datos

Parte 5 — 06_scoring_mlflow_databricks (de “no corría” a CERRADO)

Esta parte cambió por completo: **pasó de roto a resuelto y verificado**.

5.1 Qué hace

Cierra el frente: (1) **carga** el modelo calibrado entrenado en local (joblib subido al Volume — no re-entrena); (2) lo **registra en MLflow** (params + PR-AUC/Brier + signature); (3) **scorea las 19.71 M sesiones** distribuido; (4) **asigna el cluster**; (5) materializa el **Contrato 2** (user_session, prob_calibrada, segmento, segmento_nombre) en Delta.

5.2 El patrón correcto (Serverless)

El truco que lo hace viable en Free Edition: **Spark hace lo masivo, pandas solo lo que cabe**. Tres restricciones del entorno, cada una con su decisión (esto va en el informe §4.1 y es oro para el jurado de Grandes Datos):

1. **Memoria del driver:** cargar 19.71 M filas en pandas mata el driver (OOM, `exit 137`). Solución: **Spark DataFrame perezoso + pandas_udf** que procesan particiones; solo baja al driver la muestra de 300 k para el KMeans.
2. **Sin sparkContext en Serverless:** no hay broadcast. Solución: **carga del modelo desde el Volume dentro del UDF** + closures para los objetos ligeros (scalar, KMeans).
3. **Incompatibilidad de NumPy:** el modelo se serializó con NumPy 2.x (`numpy._core`); Databricks tiene 1.x. Solución: pin de versiones + alias de módulo.

5.3 El bug que cazamos (y por qué importa)

La primera corrida exitosa dio una señal mala: $\text{avg}(\text{prob_calibrada}) = 0.0275$, la mitad de la tasa base. Como el **PR-AUC también cayó** ($0.117 \rightarrow 0.081$) y el PR-AUC es de ranking (la calibración monótona no lo cambia), el problema **no era calibración: era orden de features**. MODEL_FEATURES en el 06 estaba en distinto orden que el de entrenamiento (02) — 6 features permutadas — y el scoring posicional las revolvía.

Fix: alinear MODEL_FEATURES al orden exacto del 02 + pinear `scikit-learn==1.6.1`. **Re-corrida verificada:** $\text{avg prob} = 0.0601 \approx \text{tasa base}$, PR-AUC reproduce 0.117. **Contrato 2 correcto.** (Lección de defensa: un scoring que “corre” no es un scoring “correcto”; lo validamos contra las métricas offline.)

5.4 Estado: CERRADO

Contrato 2 = 19,711,743 filas; distribución de segmentos consistente con el clustering; probabilidades reales. Ya alimenta el tablero (Kelly) y el targeting del A/B (Yeison).

Síntesis — estado y qué falta

Frente	Estado
Propensión (02)	CERRADO — LightGBM+Optuna, CV 0.1235 ± 0.0014 , test 0.1172, Brier 0.0515
Drift/split (03)	CERRADO — evidencia de Opción C; cuarentena 14–17 alineada
Clustering (04)	CERRADO — $k=5$, C3 objetivo; estabilidad confirmada por el 06
Scoring (06)	CERRADO — Contrato 2 correcto (avg 0.060), bug de orden de features resuelto
Informe	CERRADO — consolidado en <code>entrega_final/</code> , referencias APA, R4, fidelidad auditada
main	Conciliado y pusheado
Pendiente	PPT + ensayo de defensa

Apéndice — matices verificados para el Q&A (no tropezar)

- **\$250 M vs \$224 M:** el \$250 M de carritos en juego es el **total global incl. Unknown**; las barras por-categoría del tablero **excluyen Unknown** y suman ~\$224 M. No las sumes en vivo esperando \$250 M.
- **2.2 min vs C3 ~12 min:** 2.2 min es la mediana **global** de compradores; **C3** perfila ~12 min. No cites “2.2 min” con C3 en pantalla.
- **Base rate:** 5.6 % = test (para lift/Dummy); 0.0597 = base limpia global (para datos).
- **A/B (cifras):** MDE +0.5 pp (8.4 % → 8.9 %) → **~49,600 por brazo, ~99,200 total**; alcanzable en pocos días.
- **Jurado:** Marco Terán (ML). Edison Valencia (“BA/HPC”) y Mauricio Árias (“Diseño”) para narrativa/diseño; **confirmar quién juzga Grandes Datos** (el tag HPC sugiere Edison Valencia).

Apéndice — frases-ancha del profe (para soltar en la defensa)

- *“El código que corre no basta: el experimento debe ser válido, comparable y defendible.”*
- *“Accuracy puede reportar 99.8 % y no detectar ningún evento.”* (→ por eso PR-AUC)
- *“El modelo estima; el umbral decide.” / “Una probabilidad no es una acción.”*
- *“Si el test se usa para escoger el modelo o el threshold, deja de ser test.”*
- *“El futuro no entrena el modelo que evalúa el pasado.”* (→ split temporal + anti-fuga)
- *“Nunca digas «mejor modelo» sin decir según qué métrica, validación y comparación.”*
- *“El mejor k no es el que maximiza una métrica, es el que sostiene una partición defendible.” / “Cluster ≠ segmento.”*
- *“Discriminar bien no es calibrar bien.”* (→ Brier + curva de calibración)
- *“Una visualización abre una hipótesis; no cierra una decisión.”*